

Table des matières

1	On peut répartir les différentes méthodologies en plusieurs catégories.	5
1.1	Méthodes utilisant un test statistique	5
1.1.1	Learning from Time-Changing Data with Adaptive Windowing	5
1.1.2	Concept drift detection based on Fisher's Exact test	5
1.1.3	Detecting Concept Drift Using Statistical Testing	6
1.1.4	Learning with Drift Detection	7
1.1.5	Concept drift detection and adaptation with Hierarchical Hypothesis Testing	7
1.1.6	Online and Non-Parametric Drift Detection Methods Based on Hoeffding's Bounds	8
1.1.7	Wilcoxon Rank Sum Test Drift Detector	8
1.1.8	Efficient Handling of Concept Drift and Concept Evolution over Stream Data	9
1.1.9	RCD : A Recurring Concept Drift Framework	9
1.1.10	Active learning approach to concept drift problem	9
1.1.11	Concept Drift Detection : Dealing with Missing Values via Fuzzy Distance Estimations	10
1.1.12	On the reliable detection of concept drift from streaming unlabeled data	10
1.2	Méthodes à base de modèles	12
1.2.1	Tracking recurring contexts using ensemble classifiers : an application to email filtering	12
1.2.2	Learning classification rules for telecom customer call data under concept drift	12
1.2.3	An Ensemble Approach for Incremental Learning in Nonstationary Environments	13
1.2.4	Data Stream Classification Guided by Clustering on Non Stationary Environments and Extreme Verification Latency	13
1.2.5	A Novel Concept Drift Detection Method for Incremental Learning in Nonstationary Environments	14
1.2.6	Concept Drift detection and adaptation in Big Imbalance industrial IoT data using ensemble learning method of offline classifiers	15
1.2.7	Concept Drift Adaptation by exploiting historical knowledge	15
1.2.8	Handling concept drift via model reuse	16
1.2.9	Reacting to Different Types of Concept Drift : The Accuracy Updated Ensemble Algorithm	17
1.2.10	Dynamic financial distress prediction using instance selection for the disposal of concept drift	17
1.2.11	Learning under concept drift using a neuro-evolutionary ensemble	18
1.2.12	Ensemble of subset online sequential extreme learning machine for class imbalance and concept drift	18
1.2.13	Fast Adapting Ensemble : A New Algorithm for Mining Data Streams with Concept Drift	18
1.2.14	Adaptive Learning with Covariate Shift- Detection for Non-Stationary Environments	19
1.2.15	Self-Adaptive Windowing Approach for Handling Complex Concept Drift	19
1.3	Méthodes de détection non supervisées	20
1.3.1	An adaptive algorithm for anomaly and novelty detection in evolving data streams	20
1.4	Méthodes annexes	21

1.4.1	Efficient Data Stream Classification via Probabilistic Adaptive Windows	21
-------	---------------------------------------------------------------------------------	----


Définition de la dérive conceptuelle

On peut définir plusieurs type de dérives avec la formule de bayes.

$$P(y | X) = \frac{P(y)P(X | y)}{P(X)}$$

On voit avec la figure 1, différents types de dérives. La dérive (a) vient d'un changement de $P(y)$, (b) est causé par un changement de $P(X | y)$ et (c) par $P(y | X)$. Les dérives illustrées par (b) et (c) sont celles qui portent atteinte le plus au modèle. On peut aussi avoir d'autres dérives détaillé dans les exemples.

FIGURE 1 – Différents types de dérive



La dérive de type (a) peut être modeste dans la baisse de performance. Mais quand le modèle ne peut pas trouver une frontière sans faire du sur apprentissage, où dans certaines zone où la frontière laisse une zone d'incertitude, alors cette type de dérive peut être problématique.

Exemples :

- [Changement de $P(y)$] Si on cherche à prédire les transactions frauduleuses, et petit à petit, leurs proportions augmentent, il y a de plus en plus de fraudes sans que leurs définitions changent.

Toujours dans le cas de la détections des fraudes, un nouveau type de fraude est mis en œuvre, de nouveaux types de transaction apparaissent, ce sont des fraudes.

Changement de $P(X|y)$ [Changement de $P(y | X)$] Un nouveaux dispositif de sécurité est mis en place, seulement certains sites web sont autorisés pour les transactions, des transactions qui était normales sont maintenant des fraudes.

Changement du vecteur X




FIGURE 2 – Concept à l’instant t




FIGURE 3 – Concept à l’instant $t + \Delta t$

Les articles de recherche peuvent être séparés en deux catégories. Ceux qui se focalisent sur la création d’un algorithme, ou d’un schéma d’apprentissage robuste à la dérive. Et ceux qui développent des méthodes faites pour détecter la dérive, sans se préoccuper du modèle.

Évaluation des méthodes

Il existe plusieurs formes d’évaluation des méthodologies.

- Dans le cas de développement d’un nouvel algorithme, on peut comparer la qualité de ses prédictions sur un certain nombre de jeux de données (de synthèse ou réel) détaillés dans un autre document.
- Dans le cas d’une méthode de détection de dérive, on peut regarder le nombre d’observations nécessaires avant la détection de celle-ci.

Chapitre 1

On peut répartir les différentes méthodologies en plusieurs catégories.

1.1 Méthodes utilisant un test statistique

1.1.1 Learning from Time-Changing Data with Adaptive Windowing

A Bifet, R Gavalda , 2007

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données

Quel type de détection : Détection de dérive. Adaptable à tout modèles.

Mots clefs Tests Statistiques, Détection sur score de modèle.

Mots clefs : ADWIN

Résumé : Un algorithme de sélection de fenêtre d'apprentissage est présenté. L'algorithme conserve les n plus récentes observations dans une fenêtre W de taille n avant de la séparer en deux parties W_1 et W_2 de taille n_1 et n_2 tel que $n_1 + n_2 = n$.

Avec $m = \frac{1}{1/n_0 + 1/n_1}$ (moyenne harmonique de n_0 et n_1); $\delta' = \frac{\delta}{n}$ et $\epsilon_{cut} = \sqrt{\frac{1}{2m} \cdot \ln \frac{4}{\delta'}}$.

Tant que l'on observe pas $|\hat{\mu}_{W_0} - \hat{\mu}_{W_1}| \geq \epsilon_{cut}$ où $\hat{\mu}_{W_0}$ est la moyenne de la fenêtre W_0 et $\hat{\mu}_{W_1}$ celle de W_1 , on supprime les observations les plus anciennes

À quelle(s) problématique(s) l'article répond ? Détection d'une dérive, sélection des observations correspondant au concept le plus récent.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? Utiliser ADWIN pour séparer les données en concepts différents C_1, C_2, \dots, C_i avec des statistiques telles que la moyenne, la variance, les quantiles... Cela permettrait, quand un nouveau concept apparaîtrait de vérifier si l'on ne dispose pas d'autres instances de ce concept dans le cas d'un concept récurrent.

Implémentation : https://scikit-multiflow.readthedocs.io/en/stable/api/generated/skmultiflow.drift_detection.ADWIN.html#skmultiflow.drift_detection.ADWIN

1.1.2 Concept drift detection based on Fisher's Exact test

Danilo Rafael de Lima Cabral, Roberto Souto Maior de Barros, 2018

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Prédiction, classes réelles

Quel type de détection : Détection de dérive. Adaptable à tout modèles.

Mots clefs : Tests Statistiques, Détection sur score de modèle.

Résumé : L'article propose trois méthodes de détection de dérive à partir du test de Fischer fait sur les prédictions du modèle, les variantes sont en partie faites pour réduire le coût calculatoire. Les différences entre les méthodes sont les tests statistiques et la manière dont ils sont utilisés. Dans les trois cas, on suppose que l'on dispose des prédictions du modèle et de la vérité. On sépare les prédictions en 2 ensembles, les plus récentes et les anciennes, on va ensuite, à l'aide de tests statistiques regarder si une différence de distribution apparaît conséquence d'une dérive.

FPDD utilise le test de Fischer quand le nombre d'erreurs où de prédictions justes est faible (inférieur à 5) et utilise le test de l'hypothèse des proportions égales utilisé par la méthode STEPDD le cas échéant. $T(r_0, r_r, n_o, n_r) = \frac{|r_0/n_o - r_r/n_r| - 0.5 \times (1/n_o + 1/n_r)}{\sqrt{\hat{p} \times (1 - \hat{p}) \times (1/n_o + 1/n_r)}}$.

FSDD utilise le test de Fischer quand le nombre d'erreurs où de prédictions justes est inférieure à 5 et utilise le test du chi deux le cas échéant.

FTDD utilise le test de Fischer exclusivement.

Les trois méthodes sont testées avec plusieurs jeux de données contre DDM, ECDD, SEED, FHDDM, STEPDD et sortent avec en moyenne de meilleurs résultats.

À quelle(s) problématique(s) l'article répond ? Amélioration du temps de calcul et des performances de plusieurs méthodes

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? Il reste à explorer plus de tests statistiques et étudier une possible combinaison, c'est-à-dire l'utilisation de plusieurs tests en simultané et un méta modèle. Expérimenter l'impact de la taille des fenêtres d'observations prises en compte (elles sont brièvement étudiées).

1.1.3 Detecting Concept Drift Using Statistical Testing

Kyosuke Nishida and Koichiro Yamauchi, 2007

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Prédiction, classes réelles.

Quel type de détection : Détection de dérive. Adaptable à tout modèles.

Mots clefs Tests Statistiques, Détection sur score de modèle.

Résumé : L'article propose une méthode de détection de dérive à partir d'un test. On suppose que l'on dispose des prédictions du modèle et de la vérité. On sépare les prédictions en 2 ensembles, les plus récentes et les anciennes, on va ensuite, à l'aide de la statistique

$$T(r_0, r_r, n_o, n_r) = \frac{|r_0/n_o - r_r/n_r| - 0.5 \times (1/n_o + 1/n_r)}{\sqrt{\hat{p} \times (1 - \hat{p}) \times (1/n_o + 1/n_r)}}$$

rejeter ou accepter l'hypothèse de même distribution.

À quelle(s) problématique(s) l'article répond ? L'article propose une méthodologie de détection de dérive sur les scores des modèles.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? La technique laisse à désirer en présence de dérive graduelle. Taille de la fenêtre.

1.1.4 Learning with Drift Detection

João Gama, Pedro Medas, Gladys Castillo, Pedro Rodrigues, 2004

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Prédiction, classes réelles.

Quel type de détection : Détection de dérive. Adaptable à tout modèles.

Mots clefs

Résumé : Les auteurs introduisent le terme de contexte. Selon eux, au sein d'un contexte la distribution des données est stationnaire. Lors de la présence d'une dérive, celle-ci est traduite par un changement de contexte, où la distribution est stationnaires, mais plus ou moins différentes que la précédente. Le but de la méthode développée ici est d'utiliser des intervalles de confiance de la loi normale appliqué aux erreurs faites par le modèle pour détecter une dérive. L'erreur devant logiquement diminuer au fur et à mesure que le modèle dispose de données d'entraînement faisant l'hypothèse que la distribution sous-jacente est la même, quand celle-ci augmente au delà d'un certain seuil, on est en présence d'une dérive.

À quelle(s) problématique(s) l'article répond ? L'article propose une méthodologie de détection de dérive sur les scores des modèles.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? L'article ne compare pas les autres travaux, mais compare les différences de performances avec et sans la méthodologie.

1.1.5 Concept drift detection and adaptation with Hierarchical Hypothesis Testing

Shujian Yu, Zubin Abraham, Heng Wang ; 2019

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Prédiction, classes réelles.

Quel type de détection : Détection de dérive. Adaptable à tout modèles.

Mots clefs Statistical Tests, Hierarchical, Adaptive Training

Résumé : Afin de détecter une dérive conceptuelle de manière stable, les auteurs mettent en place une méthodologie à deux niveaux. Un premier niveau détecte à travers l'instabilité de 4 métriques relatant les performances du modèle, une dérive. Les auteurs en utilise 4 car l'utilisation d'une seule, comme dans d'autres méthodologies existantes, ne permet pas l'obtention d'un délais de détection rapide et de précision forte.

Si une détection est relevée, alors un deuxième test est fait en comparant les performances du modèle entraîné sur les données d'avant la dérive et d'après. Les auteurs utilisent également une version adaptable de l'algorithme SVM permettant l'utilisation des données du concept précédent afin d'améliorer les performances du nouveau modèle, peu d'exemples d'entraînements étant disponibles après détection d'un nouveau concept.

À quelle(s) problématique(s) l'article répond ? Les techniques développées permettent une détection plus rapide de la dérive. Le modèle adaptable permet de bonnes performances malgré le nombre faible d'observations.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? Rendre d'autres algorithmes Adaptables (Lire référence 54).

1.1.6 Online and Non-Parametric Drift Detection Methods Based on Hoeffding's Bounds

Frias-Blanco, Campo-Avila ; 2015

Type de Dérive : $P(X | y)$ et $P(X)$

Quelles informations utilisées dans la détection : Prédiction, classes réelles.

Quel type de détection : Détection de dérive. Adaptable à tout modèles.

Mots clefs Statistical Tests, Hierarchical, Adaptive Training

Résumé : Pour détecter une dérive au sein des données d'entraînement, les auteurs mettent en place deux méthodologies basées sur l'inégalité de Hoeffding.

Une première méthode utilise la moyenne comme critère de détection, la deuxième une moyenne pondérée.

À quelle(s) problématique(s) l'article répond ? Les techniques développées permettent une détection rapide de la dérive.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?

1.1.7 Wilcoxon Rank Sum Test Drift Detector

Roberto Souto Maior de Barro ; 2017

Type de Dérive : $P(y | X)$

Quelles informations utilisées dans la détection : Prédiction

Quel type de détection : Détection de dérive. Adaptable à tout modèles.

Mots clefs Statistical Tests

Résumé : Pour détecter une dérive au sein des données les auteurs vont effectuer un test de Wilcoxon sur les prédictions du modèle deux fenêtres, une ancienne et une récente. Contrairement à STEPDP, la taille de l'ancienne fenêtre est limitée.

À quelle(s) problématique(s) l'article répond ? Les techniques développées permettent une détection rapide de la dérive.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?

1.1.8 Efficient Handling of Concept Drift and Concept Evolution over Stream Data

Roberto Souto Maior de Barro ; 2017

Type de Dérive : $P(y | X)$, Nouvelles classes

Quelles informations utilisées dans la détection :

Quel type de détection : Détection de dérive. Adaptable à tout modèles à base de cluster.

Mots clefs Statistical Tests

Résumé : L'algorithme maintient à jour un ensemble de modèle de classification de type k plus proches voisins. À l'arrivée d'un nouvel exemple, celui-ci est prédit, mais, si il se trouve trop loin des clusters existant, alors, il est considéré comme un outlier et est stocké dans un buffer. Quand il y a assez d'exemples dans le buffer, on calcule une métrique pour chaque couple (exemple, modèle de l'ensemble). Si des exemple ne peuvent pas être rattaché à des clusters, alors on a emergence d'une nouvelle classe et ceux ci sont incorporé à un nouveau modèle.

Dès qu'une nouvelle instance doit est prédite, un score de confiance en la prediction est également calculé et stocké. S'il y a une détection de changement de distribution dans la série de valeurs de confiance des prédiction alors on à une dérive. La taille de la fenêtre est ajusté, certains exemples sont selectionné basé sur leur score de confiance et leurs labels sont récupérés (Comment ? Pas pratique) et un modèle est entraîné avec ceux-ci et remplace le plus vieux modèle de l'ensemble..

À quelle(s) problématique(s) l'article répond ? L'emergence de nouvelle classe.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?

1.1.9 RCD : A Recurring Concept Drift Framework

Gonc, Campo-Avila ; 2013

Type de Dérive : $P(X | y)$ et $P(X)$

Quelles informations utilisées dans la détection : Prédiction, classes réelles.

Quel type de détection : Détection de dérive. Adaptable à tout modèles.

Mots clefs Statistical Tests, Hierarchical, Adaptive Training

Résumé : Pour détecter un dérive au sein des données d'entraînement, les auteurs mettent en place deux méthodologie basé sur l'inéglité de Hoeffding.

Un première méthode utilise la moyenne comme critère de détéction, la deuxième une moyenne pondérées.

À quelle(s) problématique(s) l'article répond ? Les techniques développées permettent une détection rapide de la dérive.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?

1.1.10 Active learning approach to concept drift problem

BARTOSZ ; 2010

Type de Dérive : $P(X | y)$ et $P(X)$

Quelles informations utilisées dans la détection : ancien labels, vecteur X

Quel type de détection : Quand récupérer des labels. Adaptable à tout modèles.

Mots clefs : Semi-supervisé

Résumé : Ici les auteurs proposent un algorithme permettant de décider quand il est nécessaire de demander les classes réelles des instances pour un réentraînement basé sur des mesures de distance.

À quelle(s) problématique(s) l'article répond ? Drift dans un contexte semi-supervisé.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?

1.1.11 Concept Drift Detection : Dealing with Missing Values via Fuzzy Distance Estimations

Liu, Lu ; 2020

Type de Dérive : $P(X | y)$ et $P(X)$

Quelles informations utilisées dans la détection : vecteur X

Quel type de détection : Surtout pour avoir une imputation de valeur manquante non gênante dans la détection de dérive.

Mots clefs :

Résumé : Ici les auteurs proposent un algorithme un algorithme permettant l'imputation de valeurs manquantes. Cette imputation se fait de façon à garder la variance des données. En effet, on imagine que remplacer les valeurs manquantes par la moyenne en présence de dérive, ne marche pas bien avec ADWIN par exemple.

À quelle(s) problématique(s) l'article répond ? Valeurs manquantes

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?

1.1.12 On the reliable detection of concept drift from streaming unlabeled data

Tegjyot Singh Sethi, Mehmed Kantardzic ; 2017

Cité 78 fois, Elsevier

Type de Dérive : $P(X | y)$ et $P(X)$

Quelles informations utilisées dans la détection : vecteur X, modèle.

Quel type de détection : Dérive de façon non-supervisé avec informations du modèle.

Mots clefs : Non supervisé

Résumé : Les approches supervisées font l'hypothèse que l'on dispose des données labélisé. Les approches de détections non supervisées souffrent souvent d'un haut taux de faux positifs. Afin de palier à ce problème les auteurs proposent un algorithme Margin Density Drift Detection (DM3). Cet algorithme, va observer le nombre d'observation qui tombent dans le domaine d'incertitude du modèle. Si ce taux augmente, alors, on commence un stockage des données et on demande un labélisation par un oracle. Si on constate une baisse de performance alors on réentraîne le modèle. Dans le cas des modèles n'ayant pas par construction une marge d'incertitude, on va comptabiliser les observation qui tombe dans un domaine ou la classification est ambiguë.

À quelle(s) problématique(s) l'article répond ? Taux de faux positifs contrôlés.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?

1.2 Méthodes à base de modèles

1.2.1 Tracking recurring contexts using ensemble classifiers : an application to email filtering

Ioannis Katakis, Grigorios Tsoumakas, Ioannis Vlahavas, 2009

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Exemples non labélisés

Quel type de détection : Catégorisation de concept. Adaptable à tout modèles.

Mots clefs Dérive récurrente

Résumé : On suppose que les données arrivent par séries où packets, on va les projeter les données dans un espace, puis, un algorithme non supervisé va les grouper par concepts, l'espace de projection permettant de comparer les instances avec la distance euclidienne. Chaque concept différent dispose de son modèle prédictif. Quand une nouvelle série d'observations arrive, elle est projeté dans l'espace, si elle ne correspond à aucun concept, on en crée un nouveau, sinon, on score.

La projection des variables se fait comme ceci : $z_i = \begin{cases} \{P_{i,j}^v : j = 1, \dots, m, v \in V_i\}, & \text{si } f_i \text{ est nominale} \\ \{\mu_{i,j}, \sigma_{i,j} : j = 1, \dots, m\}, & \text{si } f_i \text{ est numérique} \end{cases}$

Et où : $P_{i,j}^v = P(f_i = v | c_j), i \in [1, n], j \in [1, m], v \in V_i$. Où V_i est l'ensemble des valeurs possible que peut prendre la variable f_i .

À quelle(s) problématique(s) l'article répond ? À la projection des espaces des données dans un espace euclidien.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? L'article fait l'hypothèse que des données d'un même batch appartiennent aux mêmes concepts.

1.2.2 Learning classification rules for telecom customer call data under concept drift

Black, M., Hickey, R, 2003

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Classes réelles.

Quel type de détection : Détection de dérive, nouvel algorithme à partir d'arbre de décision.

Mots clefs : Arbre de décision,

Résumé : L'article développe plusieurs versions d'une méthodologie basée sur les arbres de décisions. On suppose que les données arrivent par batches. Un attribut de temporalité est introduit dans le jeu de données. Un arbre de décision est fait sur le dataset. Si l'attribut de temps est présent dans les décisions, alors on a un drift. Cela permet également de voir quelles variables ont été impactées par le drift. Seul les règle émanant des branches qui se trouvent dans la branche de l'arbre de décision où un attribut temporel est présent sont supprimées. Les règles qui n'ont pas été impactées restent.

À quelle(s) problématique(s) l'article répond ? Utiliser la temporalité afin de trouver les attributs en dépendant.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? Utiliser cette méthode afin de vérifier si

1.2.3 An Ensemble Approach for Incremental Learning in Nonstationary Environments

Michael D. Muhlbaier and Robi Polikar, 2007

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données passées

Quel type de détection : Détection de dérive, nouvel algorithme d'apprentissage en ligne.

Mots clefs : Online learning

Résumé : L'article propose Learn⁺⁺.NSE NSE comme Non Stationnary Environment. On suppose que les données arrivent en par paquets, ou en batch. On suppose ici que les dernières données labélisées correspondent au concept le plus récent. Ainsi, à chaque fois qu'un batch de données labélisées arrive, on entraîne un nouveau modèle. On va ensuite regarder les taux d'erreurs respectifs de chaque ancien modèle sur l'ensemble des paquets de données.

On va ensuite attribuer une pondération à chaque modèle qui va dépendre des performances de ceux-ci sur les paquets de données. L'erreur des modèles sur les paquets récents va prendre plus de d'importance que les erreurs anciennes. Dans le cas d'une dérive récurrente, on va observer le poids d'un modèle osciller.

Le résultat de cette pondération va déterminer le poids de chacun des modèles dans la prédiction à venir.

À quelle(s) problématique(s) l'article répond ? L'article répond aux problèmes des dérives récurrentes.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? L'article ne prend pas en compte la séparation des paquets en concepts. En effet, deux concepts peuvent arriver au sein d'un même paquet s'ils sont trop longs. S'il sont trop courts, alors les performances du modèle seront insatisfaisantes. La méthodologie utilise seulement les performances dans son discernement des concepts, un ajout de méthodes statistiques augmenterait sûrement la pertinence de la pondération. La méthodologie entraîne un modèle unique sans se soucier des hyperparamètres.

1.2.4 Data Stream Classification Guided by Clustering on Non Stationary Environments and Extreme Verification Latency

VMA Souza, DF Silva, J Gama, GE Batista , 2015

Cité 62 fois, SIAM

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données d'initialisation.

Quel type de détection : Détection de dérive, nouvel algorithme d'apprentissage en ligne.

Mots clefs : Semi-supervisé

Résumé : On dispose des labels seulement lors de l'initialisation et c'est un contexte où une dérive est présente. L'article présente une méthodologie semi-supervisée afin de prédire dans un contexte où il y a une dérive. Le contexte est un contexte de dérive incrémentale, le nombre de classes est supposé connu et ne change pas, on dispose initialement d'un nombre d'exemples labélisés.

À l'initialisation, on va attribuer chaque exemple à un cluster selon sa classe. On aura donc autant de clusters que de classes. Les centroïdes sont calculés.

On va ensuite récupérer des exemples non labélisés, utiliser k-means pour les répartir en clusters. Pour cela, lors de l'initialisation, on utilise les centroïdes des clusters précédemment définis, par les classes, comme centroïdes d'initialisation. Une fois les nouveaux points répartis en clusters, on va attribuer aux instances non labélisées composant les clusters, le label du cluster de l'itération précédente qui est le plus proche. Les nouveaux exemples labélisés, on peut réentraîner le modèle sur les exemples les plus récents. On peut ainsi recommencer l'itération dès l'arrivée de nouveaux exemples. On oscille ainsi entre classification supervisée et clustering.

À quelle(s) problématique(s) l'article répond ? L'article apporte une méthode pour traiter la dérive dans un contexte semi-supervisé. Dans un contexte où les labels des observations ne sont disponibles que lors de l'initialisation.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? On peut imaginer que dans le cas d'une dérive de forte amplitude brusque, ou lors de dérives qui s'enchaînent sur une temporalité longue, le système perde en efficacité.

1.2.5 A Novel Concept Drift Detection Method for Incremental Learning in Nonstationary Environments

Z Yang, S Al-Dahidi, P Baraldi, E Zio, 2019

Cité 4 fois, ieeexplore.ieee.org

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Détection de dérive, méthodologie adaptable à plusieurs algorithmes.

Mots clefs : Semi-supervisé

Mots clefs : Détection par analyse du modèle

Résumé : L'article détaille une méthode qui, pour détecter la dérive, va réentraîner un modèle (ELM) Extreme Learning Machines, qui est un modèle type réseau de neurones à une unique couche cachée. Ce type de modèle a la particularité qu'il peut être actualisé avec l'arrivée de nouvelles données quel que soit leur nombre.

Une fois le modèle entraîné, à l'arrivée de nouveaux exemples labélisés, un réentraînement s'opère. La différence de poids des neurones de la couche cachée du modèle réentraîné avec les poids du modèle avant réentraînement est calculée. Les auteurs développent une distance faite pour mesurer l'écart entre les poids des deux modèles.

Si cette différence est supérieure à un seuil, dont la méthodologie de détermination est détaillée dans l'article. Un calcul, tiré de travaux récents pour quantifier le nombre d'exemples labélisés nécessaires à un réentraînement efficace du point de vue des performances prédictives et en terme de coût calculatoire.

À quelle(s) problématique(s) l'article répond ? Comment détecter une dérive avec le modèle sans regarder les performances de celui-ci ? Comment trouver le compromis idéal pour un savoir quand faire les réentraînements ?

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? Utiliser une méthodologie similaire sur d'autres algorithmes prédictif, calculer une distance entre les arbres de décisions, où trouver un seuil à partir duquel un changement des coefficients de la régression linéaire indiquerait une dérive.

1.2.6 Concept Drift detection and adaptation in Big Imbalance industrial IoT data using ensemble learning method of offline classifiers

Chun-Cheng Lin, Der-Jiunn Deng, 2019

Cité N fois, Revue

Type de Dérive : $P(X | y)$ et $P(y | X)$ Imbalanced Dataset

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Détection de dérive dans un contexte contrebalancé.

Mots clefs : Imbalanced Problems

Résumé : L'article propose une solution d'apprentissage automatique sur un problème contrebalancé en présence d'une dérive conceptuelle. Le traitement des données contrebalancées se fait par la technique SMOTE, qui permet une création de points synthétiques de la classe minoritaire. La détection de la dérive se fait par une surveillance des performances du modèle par des seuils, on a affaire à une détection par seuil statistique de 4 métriques dérivées des prédictions du modèle et de la vérité.

À quelle(s) problématique(s) l'article répond ? Adresser un problème contrebalancé.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? L'évaluation sur données réelles est faite, mais sans comparé à d'autres méthodologies.

1.2.7 Concept Drift Adaptation by exploiting historical knowledge

Yu Sun, Ke Tang, Zexuan Zhu, Xin Yao, 2018

Cité 49 fois, IEEE Explore

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Nouvel algorithme

Mots clefs :

Résumé : L'article détaille une méthode : DTEL pour prédire en présence de dérive. La méthodologie conserve un pool de modèles (des arbres de décisions) de taille fixe. On suppose les données arrivant par batch D . A l'arrivée d'un batch labélisé à l'instant t :

- Un nouveau modèle est entraîné sur les données du batch D_t
- Les anciens modèles sont actualisés de la façon suivante : Pour chacun des anciens modèles, les données du nouveau batch sont réparties dans les feuilles de l'arbre et les probabilités des feuilles sont actualisées en conséquence. Les feuilles n'ayant pas atteint un critère de stop continuent d'être séparées avec les nouvelles données jusqu'à ce que le critère de stop prenne effet. Cela permet de garder la structure de l'arbre entraîné sur des données antérieures tout en prenant en compte le batch D_t .
- On ajoute le nouveau modèle au pool, et si la taille du pool excède une taille maximum, on retire le modèle apportant le moins d'originalité selon la mesure : $\text{div}(S) = 1 - \frac{1}{\sum_{1 \leq i \neq j \leq m} 1} \sum_{1 \leq i \neq j \leq m} Q(f_i, f_j)$ où $Q(f_i, f_j) = \frac{N^{11}N^{00} - N^{01}N^{10}}{N^{11}N^{00} + N^{01}N^{10}}$ tel que N^{ab} soit le nombre d'exemple tel que le modèle f_i prédise a et que le modèle f_j prédise b . Ici 1 représente une classification correcte, et 0 une erreur.

Les modifications avec les données du nouveau batch sur les anciens modèles sont temporaires et les modèles retrouvent leur état d'origine avec l'arrivée d'un nouveau batch labélisé. Le poids qu'a chacun des modèles dans la prédiction finale est calculé en fonction des performances de ceux-ci sur le batch D_t

À quelle(s) problématique(s) l'article répond ?

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?

1.2.8 Handling concept drift via model reuse

Peng Zhao, Le-Wen Cai, Zhi-Hua Zhou, 2019

Cité 6 fois, Springer

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Nouvel Algorithme.

Mots clefs : Ensemble model

Résumé : On suppose les données arrivant de manière incrémentale et les labels arrivant peut après. La méthodologie utilise un pool de modèles linéaires. Un nouveau modèle est ajouté au pool quand une nouvelle dérive a été détectée où lorsque un nombre p d'exemples ont été vu depuis le dernier entraînement. Ici on utilise ADWIN comme détecteur de dérive.

La contribution de chacun des modèles est basé sur les performances de ceux-ci sur les derniers exemples labélisés. Lors de l'ajout d'un modèle ce dernier est entraîné en prenant compte des poids des modèles du pool.

$$\hat{\mathbf{w}}_k = \arg \min_{\mathbf{w}} \left\{ \frac{1}{m} \sum_{i=1}^m \ell(\langle \mathbf{w}, \mathbf{x}_i \rangle, y_i) + \mu \Omega(\mathbf{w}, \mathbf{w}_p) \right\}$$

où ℓ est la fonction coût, x_i et y_i les données du dernier batch S_k . On a $\mathbf{w}_p = \sum_{j=1}^{k-1} \beta_j \hat{\mathbf{w}}_j$ où β_j est le poids du modèle h_j . Ω est la fonction de pénalisation.

Si le nombre de modèle est supérieur de 1 à la taille du pool, on supprime le plus ancien.

À quelle(s) problématique(s) l'article répond ?

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? Faire un algorithme ayant de bonne performance quand on a une absence de y immédiate. Tel que les performances ne se dégradent pas trop, même si un drift a été détecté et qu'aucun exemple labélisé on été reçu. Avec une double mesure.

1.2.9 Reacting to Different Types of Concept Drift : The Accuracy Updated Ensemble Algorithm

Dariusz Brzezinski and Jerzy Stefanowski, 2014

Cité N fois,

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Nouvelle méthodologie d'apprentissage.

Mots clefs : Ensemble model

Résumé : Les auteurs proposent dans leurs approche, d'utiliser un pool de modèle, les modèles ici sont des arbres de décisions, mais tous les algorithmes pouvant être réentraînés en ligne peuvent être choisis. Avec l'arrivée d'un nouveau batch, un nouveau modèle est entraîné. Les poids que prennent chaque algorithme du pool est calculé en fonction des performances obtenues sur le dernier batch.

Les anciens modèles sont actualisés en prenant en compte le nouveau batch. Si la taille en mémoire des modèles dépasse un seuil, alors les modèles sont élagués.

À quelle(s) problématique(s) l'article répond ? L'article apporte une réponse avec à la question de taille de batch. Cette méthodologie peut s'accomoder de tout petit batch.

1.2.10 Dynamic financial distress prediction using instance selection for the disposal of concept drift

Jie Sun, Hui Li, 2011

Cité 65 fois,

Type de Dérive : $P(X | y)$ et $P(y | X)$ Dérive virtuelle

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Nouvelle méthodologie d'apprentissage.

Résumé : Spécialisé dans le monde de la finance les auteurs proposent une méthodologie qui est un regroupement de méthode existantes adapté à leurs cas d'usage. Des comparaisons de manières de sélectionner les anciens exemples labélisés sont présentés. On peut retenir une manière astucieuse dans le cas de la dérive conceptuelle : Entraîner un modèle sur les dernières données, puis, scorer les anciennes données avec ce nouveaux modèle et sélectionner les données ou le modèle est le plus précis afin de les incorporer à celui-ci.

À quelle(s) problématique(s) l'article répond ? L'article apporte une réponse avec à la question de quelle donnée utiliser pour un l'apprentissage du dernier concept.

1.2.11 Learning under concept drift using a neuro-evolutionary ensemble

Tatiana Escovedo, 2015

Cité 4 fois,

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Nouvelle méthodologie d'apprentissage.

Résumé : Les auteurs utilisent un schéma classique de gestion de la dérive. C'est à dire qu'ils procèdent à un réapprentissage systématique. L'aspect nouveaux vient de la manière dont les modèles sont sélectionnés. On utilise un ensemble de réseaux de neurones. Les poids de chaque réseaux est pondéré par un sa performance prédictive. Avec l'arrivé d'un nouveau batch de donnée un nouveau modèle est instancié. Mais les poids et biais de ce réseaux sont choisi par un algorithme génétique.

À quelle(s) problématique(s) l'article répond ? L'article ce focalise sur la qualité des prédictions. L'architecture des modèles pourrait également être sélectionné par un algorithme génétique.

1.2.12 Ensemble of subset online sequential extreme learning machine for class imbalance and concept drift

Bilal Mirza a,n, Zhiping Lin 2013

Cité 120 fois,

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Problème contrebalancé, Concept récurrent.

Résumé : Deux méthodes sont apportés pour lutter contre la dérive et les classes contrebalancés. Les auteurs utilisent autant de modèles que le ratio de classe. Si on a 10% de classe positive, alors on aura 10 modèles. Chaque modèle sera entraîné sur toute les classes positives, mais seulement sur 10% des classes négatives. Les données qui arrivent au fil de l'eau peuvent être incorporé aux modèles (Extreme Learning Machines). Quand on observe une baisse de performance (selon la métrique Gmean ; $Gmean = \sqrt{TPR \times TNR}$ ou TPR et TNR étant les taux de vrais positifs et négatifs.) Alors un nouveaux modèle est incorporé au pool entraîné sur les dernières données.

À quelle(s) problématique(s) l'article répond ? Problème contrebalancé.

1.2.13 Fast Adapting Ensemble : A New Algorithm for Mining Data Streams with Concept Drift

Agustín Ortíz Díaz,¹ José del Campo-Ávila, 2014

Cité 15 fois,

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Concept récurrent.

Résumé : La méthode fait appel à un ensemble de modèle. Les modèles peuvent être actif ou passif. Leurs status dépend de leurs performances obtenues sur les dernières données labélisées. Quand il y a détection d'un dérive qui est faite avec DDM ou EDDM alors un nouveau modèle est ajouté. DDM utilise le fait qu'une dérive apparaît lors de la détérioration des résultats. En toute logique, si un concept est récurrents, les classifieurs vont être réactivés et donc aucun nouveau modèle ne sera rajouté. Si un modèle doit être rajouté, et que le nombre de modèle du pool maximum est atteint alors, on supprime un modèle en se basant sur l'âge et les performances.

À quelle(s) problématique(s) l'article répond ?

1.2.14 Adaptive Learning with Covariate Shift- Detection for Non-Stationary Environments

Haider Raza, Girijesh Prasad, 2014

Cité 10 fois,

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Rapide

Résumé : Ici on a un seul modèle. On utilise un détecteur de dérive à deux étapes. Quand une dérive est suspectée alors on enclenche le deuxième test. Si la dérive est confirmée, alors on stocke les données relatives au nouveau concept et on attend les labels avant de procéder au réentraînement.

À quelle(s) problématique(s) l'article répond ?

1.2.15 Self-Adaptive Windowing Approach for Handling Complex Concept Drift

Imen Khamassi, Moamar Sayed-Mouchaweh, 2015

Cité 25 fois,

Type de Dérive : $P(X | y)$ et $P(y | X)$

Quelles informations utilisées dans la détection : Données labélisées.

Quel type de détection : Rapide

Résumé : L'article détaille la détection de la dérive. Celle-ci se fait en regardant le taux d'erreur d'un modèle sur deux fenêtres. Une première fenêtre englobe toutes les observations depuis le dernier drift, une autre fenêtre n'englobe que les observations récentes. On suppose les erreurs normalement distribuées ce qui nous permet de faire un test statistique. Si un niveau d'alerte est soulevé alors, on arrête d'agrandir la "grande fenêtre". Et on commence à stocker les données pour un nouvel entraînement.

À quelle(s) problématique(s) l'article répond ?

1.2.16 Scalable real-time classification of data streams with concept drift

Mark Tennant, Frederic Stahl ; 2017

Cité 53 fois, Elsevier

Type de Dérive : $P(X | y)$ et $P(X)$

Quelles informations utilisées dans la détection : vecteur X , labels.

Quel type de détection : Algorithme d'apprentissage continu fait pour le drift

Mots clefs : Plus proche voisin, parallélisable.

Résumé : Ici un modèle à base de clusters faisant un apprentissage en ligne est présenté. Avec chaque cluster on traque son taux d'erreur de prédictions. Avec chaque nouvelle observation labélisée, on fait la prédiction en lui attribuant la valeur du cluster le plus proche puis on l'ajoute au cluster ayant le même label le plus proche. Ce sera le cluster qui a fait la prédiction si celle-ci est juste. Si le taux d'erreurs devient trop grand alors on sépare le cluster en deux.

À quelle(s) problématique(s) l'article répond ? Méthode en ligne.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?

1.3 Méthodes de détection non supervisées

1.3.1 An adaptive algorithm for anomaly and novelty detection in evolving data streams

Mohamed-Rafik Bouguelia, Slawomir Nowaczyk, Amir H. Payberah ; 2018

Mots clefs : Gas Network Generator, Self Organising Maps

Résumé : L'article propose une amélioration du modèle GNG, en apportant les modifications nécessaires pour une meilleure adaptabilité à un changement de distribution.

L'algorithme des GNG est un algorithme non supervisé *online*. On initialise un nombre n de clusters ou de sommets de même dimension que le jeu de données. À chaque apparition d'un exemple x , on calcul les deux sommets les plus proches. On va décaler le sommet le plus proche légèrement en direction du nouveau point, puis on trace une arrête entre les deux sommets les plus proches d'âge 0. On incrémente de 1 toutes les arrêtes, puis, on supprime les arrêtes d'âge supérieur à un seuil. Puis, on va supprimer tous les sommets isolés. Toutes les λ itérations on va créer un nouveau sommet à partir du sommet existant ayant la distance moyenne entre ses points x et le centre la plus élevées.

Le problème de ce modèle est qu'un grand nombre de paramètres est nécessaire à son fonctionnement et donc que l'on manque d'adaptabilité, que certains vieux neurones ne sont pas supprimés alors que peu utiles.

L'algorithme proposé le GNG-A comme adaptive, l'adaptabilité signifie que l'initialisation des paramètres perd son importance les hyperparamètres évoluant. Le processus de suppression et création des sommets n'est plus systématique, mais prend en compte la dérive.

À quelle(s) problématique(s) l'article répond ? La paramétrisation des hyperparamètres n'est plus capitale, les sommets ne sont plus créés et supprimés de façon systématique. L'algorithme est maintenant utilisable complètement en ligne.

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ? On a ici un algorithme non supervisé. Adapter ces méthodes à un problème supervisé. Adapter au concepts récurrents lors de la suppression en gardant en mémoire les anciens sommets. Ne traite pas les variables n'étant pas de type numériques.

1.4 Méthodes annexes

1.4.1 Efficient Data Stream Classification via Probabilistic Adaptive Windows

Albert Bifet, Jesse Read, Bernhard Pfahringer, Geoff Holmes ; 2013

Mots clefs : Memory optimisation, online learning

Résumé : L'article détaille une méthode : DTEL pour prédire en présence de dérive. La méthodologie conserve un pool de modèles (des arbres de décisions) de taille fixe. On suppose les données arrivant par batch D . A l'arrivée d'un batch labélisé à l'instant t :

- Un nouveau modèle est entraîné sur les données du batch D_t
- Les anciens modèles sont actualisés de la façon suivante. Pour chacun des anciens modèles, les données du nouveau batch sont réparties dans les feuilles de l'arbre et les probabilités des feuilles sont actualisées en conséquence. Les feuilles n'ayant pas atteint un critère de stop continuent d'être séparées avec les nouvelles données jusqu'à ce que le critère de stop prenne effet. Cela permet de garder la structure de l'arbre entraîné sur des données antérieures tout en prenant en compte le batch D_t .
- On ajoute le nouveau modèle au pool, et si la taille du pool excède un la taille maximum, on retire le modèle apportant le moins d'originalité selon la mesure : $\text{div}(S) = 1 - \frac{1}{\sum_{1 \leq i \neq j \leq m} 1} \sum_{1 \leq i \neq j \leq m} Q(f_i, f_j)$
où $Q(f_i, f_j) = \frac{N^{11}N^{00} - N^{01}N^{10}}{N^{11}N^{00} + N^{01}N^{10}}$ tel que N^{ab} soit le nombre d'exemple tel que le modèle f_i prédise a et que le modèle f_j prédise b . Ici 1 représente une classification correcte, et 0 une erreur.

Les modifications avec les données du nouveau batch sur les anciens modèles sont temporaires et les modèles retrouvent leurs état d'origine avec l'arrivée d'un nouveau batch labélisé. Le poids qu'a chacun des modèles dans la prédiction finale est calculé en fonction des performances de ceux-ci sur le batch D_t

À quelle(s) problématique(s) l'article répond ?

Quelles sont les pistes à explorer et ont-elles été explorées par d'autres articles ?